

xCross: Um Modelo Probabilístico Para Avaliação de Cruzamentos através da Entropia

**Jalmir de Jesus Ferreira da Silva Junior¹ Vitor A. R. Azevedo¹,
Lucas V. S. Ramos¹, Eduardo A. Tomich¹, Bernardo S. B. de Oliveira¹**

¹ Departamento de Ciência da Computação – Universidade Federal de Minas Gerais (UFMG)
Belo Horizonte, MG – Brazil

Abstract. *Crosses are high-impact plays in football, often associated with significant scoring opportunities. However, their dynamic and collective nature poses challenges for statistical modeling, making it difficult to accurately capture player interactions. In this study, we introduce xCross, a probabilistic model designed to estimate the expected value of a cross. As a key contribution, we propose a novel positional entropy metric that quantifies the degree of defensive disorganization during the play, which plays a critical role in determining offensive success.*

Resumo. *Cruzamentos são jogadas de alto impacto no futebol, frequentemente associadas a oportunidades significativas de finalização. No entanto, sua natureza dinâmica e coletiva impõe desafios à modelagem estatística, dificultando a captura precisa das interações entre jogadores. Neste trabalho, apresentamos o xCross, um modelo probabilístico desenvolvido para estimar o valor esperado de um cruzamento. Como contribuição central, introduzimos uma nova métrica de entropia posicional, capaz de quantificar o grau de desorganização defensiva durante a jogada, fator que exerce papel fundamental no sucesso ofensivo.*

1. Introdução

Apesar de sua frequência no futebol, cruzamentos são estatisticamente pouco eficientes. A literatura (Vecer, 2014) aponta que, na Premier League, a média é de apenas um gol a cada 92 cruzamentos. Essa discrepância demonstra que as análises tradicionais, que se baseiam apenas em dados de eventos, não conseguem capturar a complexidade total da jogada. O valor de um cruzamento não se resume a um passe, mas sim ao contexto posicional e tático em que ele ocorre.

Com essa perspectiva, apresentamos o **xCross**, um modelo probabilístico que busca quantificar o valor esperado de um cruzamento. Nossa principal inovação é o uso da **entropia espacial**, uma medida que quantifica a desorganização defensiva. Acreditamos que, quanto maior a entropia no momento do cruzamento, mais vulnerável a defesa se encontra, e maior a chance de a jogada resultar em sucesso.

O modelo foi desenvolvido em duas versões, utilizando dados de rastreamento e eventos da temporada 2024 da Premier League:

- **xCross:** Estima o potencial da jogada no instante do cruzamento, avaliando o arranjo espacial dos jogadores sem considerar o destino final da bola.
- **xCross_on_Target:** Refina a estimativa inicial ao incluir a posição em que a bola realmente chegou, oferecendo uma análise mais precisa da trajetória.

O principal objetivo do nosso trabalho é demonstrar que a **entropia** pode ser uma métrica eficaz para medir a desorganização defensiva e, consequentemente, o potencial de uma jogada. Nosso modelo contribui para a evolução da análise esportiva, oferecendo uma ferramenta mais sofisticada e contextual para a avaliação de cruzamentos.

2. Metodologia

2.1. Padronização dos Dados

Para garantir consistência espacial entre as jogadas, padronizamos todos os lances para ocorrerem em uma única direção de ataque. As coordenadas dos eventos e do *tracking* foram transformadas de forma que todos os cruzamentos se desenvolvem da esquerda para a direita no campo. Essa abordagem nos permite comparar jogadas de forma consistente e focar em padrões espaciais, independentemente do lado do campo em que elas ocorreram.

2.2. Definição de Cruzamento

Adotamos uma definição sistemática de cruzamento, em vez de depender de anotações manuais. Consideramos como cruzamento qualquer passe realizado a partir de uma zona específica do campo (definida empiricamente) e direcionado para a área adversária. A delimitação exata das zonas de origem e destino será apresentada na Figura 6. Essa abordagem permite capturar cruzamentos que fogem do padrão convencional, mas que mantêm a mesma intenção tática.




Figure 1. Região de início do cruzamento




Figure 2. Região de destino do cruzamento

Figure 3. Zonas de origem e destino dos cruzamentos.

2.3. Definição de Sucesso

Um cruzamento é considerado bem-sucedido se a posse de bola imediata após a jogada for mantida pela equipe atacante. O sucesso é, portanto, determinado pela continuidade da posse de bola, independentemente de qual jogador a receba.

2.4. Features Extraídas a partir dos Dados de Eventos

A partir dos dados de eventos, que registram informações pontuais e posições de passes, extraímos as seguintes *features* para descrever a jogada:

- **action_1**: Tipo da ação principal (ex: cruzamento, passe curto).

- **start_x_1, start_y_1, end_x_1, end_y_1**: Coordenadas de início e fim da ação principal.
- **cross_region**: Região do campo de onde o cruzamento é originado.
- **polar_angle_entry**: Ângulo que representa a direção de entrada do jogador na zona de cruzamento.
- **polar_angle_cross**: Ângulo do vetor do cruzamento, indicando a direção do passe.
- **distance_start_from_goal**: Distância do jogador que cruzou até o gol.
- **distance_from_end_line**: Distância da bola até a linha de fundo.

2.5. Features Extraídas a partir dos Dados de Tracking

Além dos dados de eventos, utilizamos os dados de *tracking* para capturar informações dinâmicas e espaciais. As principais *features* extraídas incluem:

- **attackers_in_box** e **defenders_in_box**: Número de jogadores atacantes e defensores dentro da grande área.
- **attackers_in_zone** e **defenders_in_zone**: Número de jogadores em uma zona tática específica próxima à área.
- **num_attackers_near_action_line** e **num_defenders_near_action_line**: Quantidade de jogadores próximos à linha de ação do cruzamento.
- **box_ratio**: Razão entre a ocupação ofensiva e defensiva dentro da grande área.
- **zone_ratio**: Razão semelhante, calculada para a zona tática específica.

3. Entropia como Medida de Desorganização Defensiva

3.1. Motivação

No nosso trabalho, usamos a **entropia**, um conceito da teoria da informação, para medir a incerteza de um sistema. No futebol, isso nos permite quantificar a desorganização posicional de uma equipe, principalmente a defesa. A nossa ideia é simples: uma defesa mais desorganizada tem maior incerteza na ocupação de espaços importantes, o que cria mais oportunidades para o ataque.

Diferente de métricas mais tradicionais, como a simples contagem de jogadores, a entropia foca na distribuição e dispersão deles. Isso nos permite identificar nuances que uma análise mais superficial não capturaria, oferecendo um indicador mais completo da vulnerabilidade defensiva.




Figure 4. Entropia Geral




Figure 5. Diferença entre entropia ataque x defesa

Figure 6. Exemplos visuais de entropia no campo.

3.2. Cálculo da Entropia Espacial

Para calcular a entropia, dividimos o campo em uma grade de 120×80 células, focando na área ofensiva. Em cada *frame* do *tracking*, projetamos a posição dos jogadores para o segundo seguinte com base em sua velocidade. Para suavizar essa projeção e criar uma estimativa de densidade de presença, usamos *Kernel Density Estimation* (KDE) com uma função gaussiana.

A partir dessa densidade, calculamos a probabilidade de ocupação para cada célula da grade, separadamente para o ataque e para a defesa. A entropia posicional (H) de uma equipe é então calculada pela fórmula de Shannon:

$$H = - \sum_{i=1}^n p_i \log(p_i)$$

onde p_i é a probabilidade de presença da equipe na célula i .

3.3. Variáveis (Features) Derivadas da Entropia

A partir desses cálculos, geramos várias *features* para o modelo, que foram pensadas para capturar diferentes aspectos da entropia posicional. As principais categorias incluem:

- **Entropia Geral e por Equipe:** Calculamos a entropia média e a soma da entropia para o ataque, a defesa e o campo todo.
- **Entropia em Zonas Específicas:** Avaliamos a entropia em áreas críticas para cruzamentos, como as zonas ao redor da bola, no "primeiro pau", no "segundo pau" e na área central da grande área.

- **Diferença de Entropia:** Para entender o desequilíbrio entre as equipes, calculamos a diferença de entropia entre atacantes e defensores, tanto no campo como um todo quanto nas zonas específicas.
- **Gradiente de Entropia:** Medimos a variação da entropia em direção ao gol, o que nos ajuda a entender como a desorganização defensiva se comporta ao longo da progressão da jogada.

3.4. Integração ao Modelo

Incorporamos essas *features* de entropia aos nossos modelos. No *xCross*, elas ajudam a prever a probabilidade de um cruzamento resultar em uma finalização. Já no *xCrossOT*, usamos as *features* de entropia mais localizadas (*_in_zone*) para refinar a estimativa, focando na precisão da finalização. Acreditamos que a entropia é uma ferramenta poderosa para medir a vulnerabilidade momentânea da defesa, o que melhora a capacidade preditiva dos nossos modelos.

4. Resultados

Para avaliar o desempenho dos modelos, usamos um conjunto de 2.448 cruzamentos, sendo 562 deles considerados bem-sucedidos. Dividimos os dados em 80% para treino e 20% para teste, de forma estratificada. O treinamento foi feito com o *XGBoost*, ajustando os hiperparâmetros por validação cruzada e calibrando as previsões com o *Calibrated-ClassifierCV*.

Apresentamos os resultados de duas versões: o **xCross**, que avalia o potencial de qualquer cruzamento com base apenas na sua posição inicial, e o **xCrossOT**, que refina essa análise ao incluir a informação de onde a bola realmente foi, usando *features* locais adicionais.

4.1. Desempenho do Modelo xCross

O modelo **xCross** obteve uma área sob a curva (AUC) de 0,62 na curva ROC (Figura 7), um resultado razoável para a tarefa de distinguir entre cruzamentos que dão certo e os que não dão. A curva de calibração mostra que o modelo mantém boas previsões até uma probabilidade de 0,7 (Figura 4.1), e o histograma confirma uma boa distribuição das probabilidades.

A análise de importância das variáveis via SHAP (Figura 10) revelou um resultado importante: as *features* de **entropia espacial** foram cruciais. Variáveis como *entropy_diff_around* e *entropy_defense_around* tiveram grande destaque, o que valida nossa hipótese de que a desorganização defensiva é um fator-chave para o sucesso de um cruzamento.

Analisando o ranking de jogadores (Tabela 1), o modelo identificou que o lateral Kieran Trippier, com uma média de 0,392, não só cruza com frequência, mas também com alta qualidade. A lista inclui principalmente laterais e pontas de destaque, como Pervis Estupiñán e Gabriel Martinelli, confirmando que essas posições são as mais eficazes para a criação de jogadas a partir das laterais.




Figure 7. Curva ROC do modelo xCross.




Figure 8. Curva de calibração do modelo xCross.




Figure 9. Histograma das probabilidades previstas pelo modelo xCross.




Figure 10. Importância das variáveis no modelo *xCross*, segundo SHAP.

Table 1. Top 10 jogadores segundo o modelo *xCross*

Jogador	Cruzamentos	Média <i>xCross</i>	Soma <i>xCross</i>
Kieran Trippier	25	0,392	9,789
Jack Harrison	24	0,319	7,646
Mads R. Rasmussen	20	0,315	6,302
Pervis Estupiñán	25	0,309	7,725
Malo Gusto	26	0,307	7,990
Diogo Dalot	27	0,303	8,176
Timothy Castagne	20	0,294	5,882
Gabriel Martinelli	26	0,290	7,546
Dejan Kulusevski	22	0,288	6,339
Dwight McNeil	32	0,286	9,138

4.2. Desempenho do Modelo *xCrossOT*

O modelo *xCrossOT* mostrou um desempenho superior, com uma AUC de 0,74 (Figura 11). Ele foi mais eficaz em prever se um cruzamento seria bem-sucedido, pois

teve acesso à informação da posição final da bola. A curva de calibração (Figura 4.2) confirma que as previsões são bem calibradas, e o histograma mostra uma distribuição mais equilibrada das probabilidades.

Neste modelo, as variáveis mais importantes (Figura 14) foram as coordenadas finais (`end_x` e `end_y`), o que faz sentido, já que o modelo leva em conta o destino da bola. No entanto, as *features* de entropia local, como `entropy_general_in_zone`, também tiveram um peso significativo, reforçando que a desorganização defensiva no ponto de chegada do cruzamento é fundamental.

A Tabela 2 apresenta os jogadores com melhor performance neste modelo. Per-vis Estupiñán e Kieran Trippier se destacam novamente, indicando que a qualidade dos seus cruzamentos não se resume apenas a uma boa posição inicial, mas também a uma execução precisa que posiciona a bola em uma área perigosa.




Figure 11. Curva ROC do modelo *xCrossOT*




Figure 12. Curva de calibração do modelo *xCrossOT*




Figure 13. Histograma das probabilidades previstas pelo modelo




Figure 14. Importância das variáveis no modelo xCrossOT segundo SHAP

Table 2. Top 10 jogadores segundo o modelo xCrossOT

Jogador	Nº Cruzamentos	Valor Médio	Valor Total
Pervis Estupiñán	25	0,3625	9,06
Kieran Trippier	25	0,3477	8,69
Mohammed Kudus	33	0,3337	11,01
Malo Gusto	26	0,3246	8,44
Simon Adingra	20	0,3242	6,48
Gabriel Martinelli	26	0,3234	8,41
Jack Harrison	24	0,3227	7,74
Vladimir Coufal	38	0,3155	11,99
Kyle Walker	22	0,3073	6,76
Pedro Neto	39	0,3016	11,76

4.3. Análise Comparativa: xCross vs. xCrossOT

A Figura 15 mostra a relação entre as duas métricas. O eixo X representa o **valor médio de cruzamento** (*mean_xCross*), que mede o potencial da jogada no início, enquanto o eixo Y representa o **valor médio com informação de destino** (*mean_xCrossOT*).

Como esperado, a correlação entre as duas métricas é positiva, o que sugere que jogadores que iniciam cruzamentos de posições favoráveis tendem a ser mais eficazes em direcioná-los para a área perigosa.

No entanto, a dispersão dos pontos no gráfico é a parte mais importante. Ela mostra que as duas métricas não são iguais, e essa diferença é o ponto-chave do nosso trabalho.

- **Jogadores de alta eficácia** (canto superior direito do gráfico): Atletas como Estupinã e Trippier, por exemplo, se destacam nas duas métricas. Isso sugere que eles não só escolhem o momento certo para cruzar, mas também executam a jogada com alta precisão, direcionando a bola para uma zona de perigo.
- **Jogadores de eficácia variável**: Outros jogadores podem ter um *xCross* razoavelmente alto, mas um *xCrossOT* mais baixo. Isso indica que, embora eles tenham potencial para criar perigo, a execução do passe em si pode não ser tão precisa, posicionando a bola em uma área de menor risco.

A existência dessas variações confirma a importância do modelo **xCrossOT**. Ele nos dá uma visão mais refinada, capturando nuances da qualidade da execução do cruzamento que o modelo *xCross*, por si só, não conseguiria. A diferença entre as duas métricas para um mesmo jogador pode ser um bom indicador da sua precisão técnica e capacidade de finalizar a jogada.




Figure 15. Relação entre a Média de Cruzamentos e a Média de Cruzamentos no Alvo.

5. Conclusão

Nosso trabalho propôs o **xCross**, um novo modelo para avaliar a qualidade de cruzamentos no futebol, utilizando a **entropia espacial** como uma medida de desorganização defensiva. O objetivo era ir além das métricas tradicionais, que ignoram o complexo contexto posicional das jogadas.

Os resultados obtidos com os modelos **xCross** e **xCrossOT** validam nossa hipótese central. A análise de importância das variáveis (SHAP) confirmou que as métricas de entropia, que quantificam a desorganização da defesa, são cruciais para a capacidade preditiva do modelo. Isso demonstra que a entropia é, de fato, um bom indicador da vulnerabilidade defensiva no momento de um cruzamento.

A comparação entre as duas versões do modelo foi outro ponto-chave. O **xCross**, que avalia o potencial da jogada com base apenas na posição inicial, e o **xCrossOT**, que incorpora a informação do destino da bola, mostraram uma correlação positiva. No entanto, a análise de dispersão revelou que as métricas não são idênticas. Essa diferença é o que torna o **xCrossOT** particularmente valioso, pois ele captura a qualidade da execução técnica de um jogador, algo que o primeiro modelo não consegue. Essa nuance nos permite diferenciar entre jogadores que têm bom posicionamento para cruzar e aqueles que, além de se posicionarem bem, também executam o passe com precisão para uma área perigosa.

Em resumo, nosso estudo oferece uma contribuição importante para a análise espacial no futebol, mostrando que métricas baseadas em entropia podem ser usadas de forma eficaz para avaliar o impacto tático e a técnica de jogadores. Para trabalhos futuros, seria interessante explorar o uso de redes neurais para capturar padrões espaciais ainda mais complexos ou aplicar a metodologia em outras jogadas, como passes longos e lançamentos, para expandir a compreensão sobre o valor posicional no futebol.

Referências

- Decroos, T., Bransen, L., Van Haaren, J., & Davis, J. (2019). Actions speak louder than goals: Valuing player actions in soccer. In Proceedings of the 25th ACM SIGKDD Conference on Knowledge Discovery & Data Mining (pp. 1851–1861).
- Fernández, J., Bornn, L., & Cervone, D. (2019). Decomposing the immeasurable sport: A deep learning expected possession value framework for soccer. Sloan Sports Analytics Conference.
- Vecer, Jan, Crossing in Soccer has a Strong Negative Impact on Scoring: Evidence from the English Premier League the German Bundesliga and the World Cup 2014 (September 30, 2014).