

xCross: Um Modelo Probabilístico Para Avaliação de Cruzamentos através da Entropia

Jalmir Ferreira¹

¹ Departamento de Ciência da Computação – Universidade Federal de Minas Gerais (UFMG)
Belo Horizonte, MG – Brazil

Abstract. Crosses are high-impact plays in football, often associated with significant scoring opportunities. However, their dynamic and collective nature poses challenges for statistical modeling. In this study we present xCross, a probabilistic model that estimates the expected value of a cross, whose key contribution is a positional entropy metric that quantifies defensive disorganization. Because the practical goal is to rank players rather than classify a single play, we evaluate the model on 7,510 crosses from three leagues using out-of-fold prediction grouped by match (no leakage), and we judge it on calibration, ranking reproducibility and predictive validity. We show that ranking players by their raw cross-success rate is essentially noise, whereas xCross yields a stable ranking that predicts future success, and we measure the contribution of the entropy features directly through ablation.

Resumo. Cruzamentos são jogadas de alto impacto no futebol, frequentemente associadas a oportunidades significativas de finalização. No entanto, sua natureza dinâmica e coletiva impõe desafios à modelagem estatística. Neste trabalho apresentamos o xCross, um modelo probabilístico que estima o valor esperado de um cruzamento e cuja contribuição central é uma métrica de entropia posicional, capaz de quantificar a desorganização defensiva. Como o objetivo prático é ranquear jogadores, e não classificar uma jogada isolada, avaliamos o modelo em 7.510 cruzamentos de três ligas com predição out-of-fold agrupada por partida (sem vazamento), julgando-o por calibração, reprodutibilidade do ranking e validade preditiva. Mostramos que ranquear jogadores pela taxa bruta de acerto é praticamente ruído, ao passo que o xCross produz um ranking estável que prevê o desempenho futuro, e medimos a contribuição das features de entropia diretamente por ablação.

1. Introdução

Apesar de sua frequência no futebol, cruzamentos são estatisticamente pouco eficientes. A literatura (Vecer, 2014) aponta que, na Premier League, a média é de apenas um gol a cada 92 cruzamentos. Essa discrepância demonstra que as análises tradicionais, que se baseiam apenas em dados de eventos, não conseguem capturar a complexidade total da jogada. O valor de um cruzamento não se resume a um passe, mas sim ao contexto posicional e tático em que ele ocorre.

Com essa perspectiva, apresentamos o xCross, um modelo probabilístico que busca quantificar o valor esperado de um cruzamento. Nossa principal inovação

é o uso da entropia espacial, uma medida que quantifica a desorganização defensiva. Acreditamos que, quanto maior a entropia no momento do cruzamento, mais vulnerável a defesa se encontra, e maior a chance de a jogada resultar em sucesso.

Diferentemente de uma versão preliminar deste trabalho, restrita a uma única temporada da Premier League e avaliada por uma divisão simples de treino e teste, aqui ampliamos a base para 7.510 cruzamentos de três ligas e adotamos uma avaliação mais rigorosa. O ponto central é que o objetivo final não é classificar um cruzamento como 0 ou 1, mas produzir uma probabilidade calibrada que, agregada por jogador, permita avaliar a qualidade de quem cruza. Por isso julgamos o modelo por três eixos: a probabilidade está correta (calibração)? ela separa cruzamentos (discriminação)? e o ranking de jogadores é reproduzível (estabilidade)?

O modelo foi desenvolvido em duas versões:

- xCross: Estima o potencial da jogada no instante do cruzamento, avaliando o arranjo espacial dos jogadores sem considerar o destino final da bola.
- xCrossOT: Refina a estimativa inicial ao incluir a posição em que a bola realmente chegou, oferecendo uma análise mais precisa da trajetória.

O principal objetivo do nosso trabalho é demonstrar que a entropia pode ser uma métrica eficaz para medir a desorganização defensiva e, conseqüentemente, o potencial de uma jogada — e, sobretudo, mostrar que um modelo de valor esperado é uma forma mais confiável de avaliar jogadores do que as estatísticas brutas.

2. Metodologia

2.1. Padronização dos Dados

Para garantir consistência espacial entre as jogadas, padronizamos todos os lances para ocorrerem em uma única direção de ataque. As coordenadas dos eventos e do tracking foram transformadas de forma que todos os cruzamentos se desenvolvem em direção ao mesmo gol e a partir do mesmo lado do campo. Essa abordagem nos permite comparar jogadas de forma consistente e focar em padrões espaciais, independentemente do lado do campo em que elas ocorreram. Utilizamos dados de rastreamento e eventos da PFF FC.

2.2. Definição de Cruzamento

Adotamos uma definição sistemática de cruzamento, em vez de depender de anotações manuais. Consideramos como cruzamento qualquer passe realizado a partir de uma zona de origem específica do campo (definida empiricamente) e direcionado para a zona de destino próxima à área adversária. Cada cruzamento é delimitado por uma janela temporal que vai do evento de posse que o origina até o próximo evento de posse, saída de bola, ou um teto de cinco segundos. Essa abordagem permite capturar cruzamentos que fogem do padrão convencional, mas que mantêm a mesma intenção tática.

2.3. Definição de Sucesso

Um cruzamento é considerado bem-sucedido se a posse de bola imediata após a jogada for mantida pela equipe atacante. O sucesso é, portanto, determinado pela

continuidade da posse de bola, independentemente de qual jogador a receba. Como rótulo alternativo, também avaliamos se o cruzamento resulta em uma finalização dentro da janela; os resultados são consistentes entre os dois rótulos, e apresentamos o rótulo de posse como principal.

2.4. Features Extraídas a partir dos Dados de Eventos

A partir dos dados de eventos, que registram informações pontuais e posições de passes, extraímos as seguintes features para descrever a jogada:

- `start_x`, `start_y`, `end_x`, `end_y`: Coordenadas de início e fim do cruzamento.
- `cross_region`: Região do campo de onde o cruzamento é originado.
- `polar_angle_cross`: Ângulo do vetor do cruzamento, indicando a direção do passe.
- `distance_start_from_goal`: Distância do jogador que cruzou até o gol.
- `distance_from_end_line`: Distância da bola até a linha de fundo.

2.5. Features Extraídas a partir dos Dados de Tracking

Além dos dados de eventos, utilizamos os dados de tracking para capturar informações dinâmicas e espaciais. As principais features extraídas incluem:

- `attackers_in_box` e `defenders_in_box`: Número de jogadores atacantes e defensores dentro da grande área.
- `attackers_in_zone` e `defenders_in_zone`: Número de jogadores em uma zona tática específica próxima à área.
- `attackers_near_action_line` e `defenders_near_action_line`: Quantidade de jogadores próximos à linha de ação do cruzamento.
- `box_ratio` e `zone_ratio`: Razões entre a ocupação ofensiva e defensiva na grande área e na zona tática.
- `pitch_control`: Probabilidade de a equipe atacante controlar cada região (modelo de tempo de chegada), resumida por zona.

3. Entropia como Medida de Desorganização Defensiva

3.1. Motivação

No nosso trabalho, usamos a entropia, um conceito da teoria da informação, para medir a incerteza de um sistema. No futebol, isso nos permite quantificar a desorganização posicional de uma equipe, principalmente a defesa. A nossa ideia é simples: uma defesa mais desorganizada tem maior incerteza na ocupação de espaços importantes, o que cria mais oportunidades para o ataque.

Diferente de métricas mais tradicionais, como a simples contagem de jogadores, a entropia foca na distribuição e dispersão deles. Isso nos permite identificar nuances que uma análise mais superficial não capturaria, oferecendo um indicador mais completo da vulnerabilidade defensiva.




Figure 1. Um mesmo cruzamento em quatro visões: tracking bruto, entropia posicional, diferença de entropia (ataque menos defesa) e pitch control. A entropia lê onde os jogadores estão; o pitch control, quem domina o espaço.

3.2. Cálculo da Entropia Espacial

Para calcular a entropia, dividimos o campo em uma grade de 120×80 células, focando na área ofensiva. Em cada frame do tracking, projetamos a posição dos jogadores para o segundo seguinte com base em sua velocidade. Para suavizar essa projeção e criar uma estimativa de densidade de presença, usamos Kernel Density Estimation (KDE) com uma função gaussiana.

A partir dessa densidade, calculamos a probabilidade de ocupação para cada célula da grade, separadamente para o ataque e para a defesa. A entropia posicional (H) de uma equipe é então calculada pela fórmula de Shannon:

$$H = - \sum_{i=1}^n p_i \log(p_i)$$

onde p_i é a probabilidade de presença da equipe na célula i .

3.3. Variáveis (Features) Derivadas da Entropia

A partir desses cálculos, geramos várias features para o modelo, que foram pensadas para capturar diferentes aspectos da entropia posicional. As principais categorias incluem:

- Entropia Geral e por Equipe: a entropia média e a soma da entropia para o ataque, a defesa e o campo todo.
- Entropia em Zonas Específicas: a entropia em áreas críticas para cruzamentos, como as zonas ao redor da bola, no "primeiro pau", no "segundo pau" e na área central da grande área.
- Diferença de Entropia: a diferença de entropia entre atacantes e defensores, tanto no campo como um todo quanto nas zonas específicas.
- Gradiente de Entropia: a variação da entropia em direção ao gol, ajudando a entender como a desorganização defensiva se comporta ao longo da progressão da jogada.

3.4. Integração ao Modelo

Incorporamos essas features de entropia aos nossos modelos. No xCross, elas descrevem a configuração no instante do cruzamento. Já no xCrossOT, usamos também as features de entropia mais localizadas (`_in_zone`), na zona de chegada da

bola. Ao todo, as features de entropia representam cerca de metade das variáveis do modelo, o que torna importante medir explicitamente o quanto elas contribuem (Seção 5.6).

4. Modelagem e Avaliação

4.1. Dados e Validação

Utilizamos um conjunto de 7.510 cruzamentos (aproximadamente 35% bem-sucedidos) de três ligas: Premier League (4.232), Brasileirão (3.000) e Bundesliga (278). Como o objetivo é ranquear jogadores, precisamos de uma predição para todo cruzamento; por isso usamos validação cruzada em 5 folds com predição out-of-fold (OOF). Os folds são formados com `StratifiedGroupKFold` agrupando por partida, de modo que nenhum cruzamento de um mesmo jogo apareça em treino e teste — isso evita o vazamento de contexto que infla as métricas. A calibração é feita de forma aninhada, com `CalibratedClassifierCV` dentro de cada fold de treino, comparando as variantes isotonic e sigmoid e escolhendo a de menor erro de calibração.

4.2. Modelos Comparados e Seleção

Comparamos três estimadores tabulares — XGBoost, AdaBoost e CatBoost — mantidos pouco regularizados para preservar a dispersão das probabilidades. Para o nosso objetivo, o critério de escolha não é apenas a discriminação, mas a estabilidade do ranking por jogador: o AdaBoost foi selecionado por apresentar a maior reprodutibilidade em todos os casos, sendo o modelo final reportado.

4.3. Métricas Alinhadas ao Objetivo

Avaliamos as probabilidades OOF (sem vazamento) em quatro frentes:

- Discriminação: ROC-AUC.
- Calibração: curva de confiabilidade, Brier skill score e Expected Calibration Error (ECE).
- Reprodutibilidade do ranking: estabilidade split-half (correlação de Spearman entre duas metades dos cruzamentos de cada jogador) e o Intraclass Correlation (ICC). Reportamos também uma versão temporal (metades cronológicas, jogos iniciais vs. finais).
- Validade preditiva: o quanto os cruzamentos passados de um jogador preveem seu sucesso futuro.

5. Resultados

5.1. Desempenho do Modelo xCross

O modelo xCross obteve uma AUC de 0,57, valor inferior ao de uma divisão simples de treino/teste justamente porque a validação agrupada por partida elimina o vazamento de contexto — uma estimativa mais honesta. A calibração é boa em toda a faixa (ECE = 0,009), como mostra a Figura 2, e o histograma confirma a distribuição das probabilidades.

A análise de dependência parcial (Figura 3) — que mostra a direção e a forma do efeito de cada variável no modelo final — confirma o papel da entropia e

do pitch control: configurações com maior entropia do ataque e maior controle de território elevam a probabilidade prevista.

O ranking de jogadores (Tabela 1) é encabeçado por meias e laterais criativos, como Martin Ödegaard, Declan Rice e Bryan Mbeumo, confirmando que essas funções concentram as melhores situações de cruzamento.




Figure 2. Calibração (esquerda) e distribuição das probabilidades (direita) do modelo xCross.




Figure 3. Efeito de cada variável (dependência parcial) no modelo xCross final.

Table 1. Top 10 jogadores segundo o modelo xCross (rótulo de posse).

Jogador	Cruzamentos	Média xCross	Soma xCross
Martin Ödegaard	22	0,415	9,13
Declan Rice	30	0,401	12,02
Eberechi Eze	33	0,400	13,20
Dwight McNeil	36	0,393	14,13
Bryan Mbeumo	66	0,392	25,90
Youri Tielemans	26	0,392	10,18
Bruno Fernandes	51	0,388	19,81
Guilherme	24	0,387	9,28
Giorgian De Arrascaeta	27	0,386	10,43
Leif Davis	42	0,385	16,18

5.2. Desempenho do Modelo xCrossOT

O modelo xCrossOT mostrou desempenho superior em discriminação, com uma AUC de 0,78 e um Brier skill de 0,21, pois tem acesso à posição final da bola. A calibração permanece boa (Figura 4). Como esperado, as variáveis mais influentes (Figura 5) são as coordenadas finais — sobretudo `end_y` — junto de

pitch_control_in_zone, polar_angle_cross e da entropia na zona de chegada, reforçando que a desorganização defensiva no ponto de chegada é relevante. A Tabela 2 apresenta os jogadores de melhor desempenho neste modelo.




Figure 4. Calibração (esquerda) e distribuição das probabilidades (direita) do modelo xCrossOT.




Figure 5. Efeito de cada variável (dependência parcial) no modelo xCrossOT final.

Table 2. Top 10 jogadores segundo o modelo xCrossOT (rótulo de posse).

Jogador	Nº Cruzamentos	Valor Médio	Valor Total
Declan Rice	30	0,492	14,77
Martin Ödegaard	22	0,485	10,68
Phil Foden	21	0,474	9,95
Fagner	36	0,459	16,53
Dwight McNeil	36	0,456	16,43
Pervis Estupiñán	41	0,456	18,70
Enzo Fernández	21	0,450	9,44
Omari Hutchinson	35	0,447	15,63
Leonel Di Placido	25	0,437	10,93
Pedro Neto	52	0,433	22,53

5.3. Análise Comparativa: xCross vs. xCrossOT

A Figura 6 mostra a relação entre as duas métricas por jogador, dividida em quadrantes pelas medianas ($\text{xCross} = 0,354$; $\text{xCrossOT} = 0,361$). O eixo X representa o potencial da jogada no início (xCross); o eixo Y, o valor com informação de destino (xCrossOT). A correlação é positiva — quem inicia cruzamentos de boas posições tende a direcioná-los para zonas perigosas — mas a dispersão é a parte importante: jogadores no canto superior direito (bom contexto e bom destino) se distinguem daqueles com bom contexto mas destino mais fraco.




Figure 6. Relação entre a média de xCross e a média de xCrossOT por jogador, em quadrantes.

5.4. Confiabilidade do Ranking: Modelo vs. Taxa Bruta

Aqui está o resultado central deste trabalho. Comparamos três formas de ranquear jogadores: pela taxa bruta de sucesso, pelo xCross e pelo xCrossOT. A Tabela 3 e a Figura 7 mostram que ranquear pela taxa bruta é praticamente ruído (estabilidade 0,06): a porcentagem de cruzamentos certos de um jogador não se reproduz entre metades de seus dados. Ao pontuar a situação em vez do desfecho, o xCross recupera um ranking estável (estabilidade 0,76; versão temporal 0,70). Essa é a justificativa central de um modelo de valor esperado frente às estatísticas brutas, e explica por que o xCross, embora "achatado", é informativo: o sucesso do cruzamento é em grande parte determinado pela situação, mas de forma estável.

Table 3. Reprodutibilidade do ranking por forma de ranqueamento (rótulo de posse).

Ranqueamento	Estabilidade (aleatória)	Estabilidade (temporal)	ICC
Taxa bruta de sucesso	0,06	0,07	0,01
xCross	0,76	0,70	0,13
xCrossOT	0,30	0,21	0,03




Figure 7. Reprodutibilidade do ranking: a taxa bruta é ruído; o xCross recupera um ranking estável.

5.5. Validade Preditiva

Como teste mais exigente, usamos apenas os cruzamentos iniciais de cada jogador para prever a taxa de sucesso real de seus cruzamentos finais. A taxa bruta passada prevê o futuro com correlação de apenas +0,07, enquanto o xCross passado prevê o sucesso futuro com +0,21 — cerca de três vezes melhor. O modelo não é apenas autoconsistente: ele antecipa o desempenho futuro.

5.6. Contribuição da Entropia (Ablação)

Para medir diretamente o impacto da entropia — e não apenas inferi-lo por importância de variáveis — treinamos cada modelo com e sem o bloco inteiro de entropia (aproximadamente metade das features), mantendo o mesmo estimador. A Tabela 4 e a Figura 8 resumem o efeito. A entropia ajuda — confirmando a direção da nossa hipótese — mas de forma moderada, não dominante: remover todas as variáveis de entropia custa cerca de 0,01–0,015 de AUC. O ganho se concentra no xCrossOT (entropia da zona de chegada), onde eleva a estabilidade em cerca de 0,10. Parte do sinal da entropia é redundante com as variáveis de posição e de pitch control.

Table 4. Ablação da entropia: cada modelo com e sem o bloco de entropia (rótulo de posse).

Modelo	Variante	Nº features	AUC	Estabilidade
xCross	com entropia	45	0,567	0,763
xCross	sem entropia	21	0,557	0,705
xCrossOT	com entropia	56	0,777	0,303
xCrossOT	sem entropia	28	0,762	0,197




Figure 8. Impacto das features de entropia: cada modelo com (verde) e sem (cinza) o bloco de entropia.

5.7. Generalização entre Ligas

Avaliando as métricas por liga separadamente, o comportamento se mantém: a estabilidade do xCross é alta tanto na Premier League (0,79) quanto no Brasileirão (0,62), e a AUC do xCrossOT fica em torno de 0,77 nas duas. O resultado não é, portanto, um artefato de uma única liga.

6. Limitações

Por honestidade, registramos os limites do estudo. (i) Cobertura: apenas 115 dos 891 cruzadores (13%) atingem o mínimo de 20 cruzamentos necessário para entrar no ranking — embora esses concentrem metade de todos os cruzamentos. (ii) Gradiente raso: o xCross varia pouco entre jogadores (de 0,32 a 0,42), de modo que os extremos são distinguíveis, mas o meio da tabela é um pelotão dentro da margem de incerteza. (iii) Habilidade vs. papel: como o xCross usa a posição de companheiros e adversários, ele mede a qualidade das situações de cruzamento em que o jogador se envolve (habilidade + função + time), não a habilidade individual isolada. (iv) A diferença xCrossOT — xCross (execução) depende do desfecho cru e é, portanto, instável, não devendo ser lida como um ranking fino de precisão técnica.

7. Conclusão

Nosso trabalho propôs o xCross, um modelo para avaliar a qualidade de cruzamentos no futebol usando a entropia espacial como medida de desorganização defensiva, e

o avaliou de forma alinhada ao seu objetivo prático: ranquear jogadores.

O principal achado é que ranquear jogadores pela taxa bruta de acerto é praticamente ruído, ao passo que o xCross — por pontuar a situação, não o desfecho — produz um ranking estável e preditivo do desempenho futuro. A ablação confirma que a entropia contribui para a capacidade do modelo, embora de forma mais moderada do que a análise de importância isolada sugeriria, com maior efeito no xCrossOT. A comparação entre as duas versões mostra que elas não são idênticas, e essa diferença ajuda a separar bom posicionamento de boa execução — com a ressalva de que a parte de execução é a menos estável.

Em resumo, o estudo reforça que métricas baseadas em entropia são úteis para a análise espacial no futebol e, principalmente, que um modelo de valor esperado bem validado é uma forma mais confiável de avaliar jogadores do que estatísticas brutas. Para trabalhos futuros, pretendemos explorar arquiteturas profundas (CNNs, Transformers) capazes de capturar diretamente os padrões espaciais a partir dos mapas, em vez de resumi-los em features.

Referências

Decroos, T., Bransen, L., Van Haaren, J., & Davis, J. (2019). Actions speak louder than goals: Valuing player actions in soccer. In Proceedings of the 25th ACM SIGKDD Conference on Knowledge Discovery & Data Mining (pp. 1851–1861).

Fernández, J., Bornn, L., & Cervone, D. (2019). Decomposing the immeasurable sport: A deep learning expected possession value framework for soccer. Sloan Sports Analytics Conference.

Vecer, Jan, Crossing in Soccer has a Strong Negative Impact on Scoring: Evidence from the English Premier League the German Bundesliga and the World Cup 2014 (September 30, 2014).